# 基于零售交易数据的用户价值与品类结构分析

学　　院：数据科学学院

专业班级：数据科学与大数据技术 大数据 241 班

学　　号：2024459985127

姓　　名：秦子睿

完成日期：2026 年 10 月

## 《商业数据分析》期末大作业评分表

| 评分维度 | 评分要点（子项及分值） | 得分 |
|---|---|---|
| 1. 数据获取合规性与清洗质量（15 分） | ① 来源合规、白名单方式、合规声明完整（5）；② 数据量达标、抽样方法与随机种子说明（4）；③ 清洗完整、异常/缺失/重复处理、多表对齐（4）；④ 可导出 CSV/JSON/SQLite 复用（2） | |
| 2. 商业分析模型应用深度（20 分） | ① 模型 ≥3 种、选型与场景匹配（6）；② 计算正确、参数与阈值有业务依据（6）；③ 预测类含置信区间与回测误差（4）；④ 结论与模型一一对应（4） | |
| 3. 可视化复现与大屏质量（25 分） | ① 图表 ≥10 张、类别覆盖全面（6）；② 模板复现 ≥10 种、风格细节贴近原作（7）；③ 业务模型图 ≥6 张（6）；④ 交互大屏 ≥1 个、组件 ≥6、有联动（6） | |
| 4. 代码规范性与文档完整性（10 分） | ① 目录结构清晰、注释充分（3）；② README 详实、依赖明确（3）；③ 可一键复现（2）；④ 图表命名与索引规范（2） | |
| 5. 期末大论文质量（25 分） | ① 题目创新性与针对性（4）；② 摘要与关键词相关性（4）；③ 正文逻辑性与技术深度（10）；④ 商业建议可行性与数据支撑（7） | |
| 6. 创新性与商业洞察深度（5 分） | ① 引入新工具/新方法（2）；② 提出有效商业建议（2）；③ 体现批判性思维（1） | |
| 总　分 | （各维度得分相加） | |

# 基于零售交易数据的用户价值与品类结构分析

秦子睿

（嘉兴大学　数据科学学院）

**摘要：**本文以 UCI Machine Learning Repository 公开发布的 Online Retail II 跨国零售交易数据集为研究对象，采用数据源官方一次性下载文件（ZIP）的白名单方式合规获取 1,067,371 条原始明细记录，经「按发票整单 30% 随机抽样」（随机种子 2026）后得到 315,722 行样本，在保证购物篮结构完整的前提下将数据规模控制在可分析区间。数据治理阶段通过重复值剔除、缺失值标记、四类异常值规则过滤与主外键一致性校验，保留 302,786 行有效明细，并将其重构为含 4 张维度表的星型模型，同时导出 CSV、JSON、SQLite 三种格式以支持复用验证。分析环节构建 RFM 八分类、同期群留存、帕累托 ABC 分类、Apriori 关联规则、波士顿矩阵、SARIMA 与 Holt-Winters 时间序列预测、K-Means 用户分群、复购漏斗共 8 类商业分析模型，各模型参数均给出业务依据，预测类模型输出点预测与 95% 置信区间并完成 30 天留出回测。可视化环节以 Matplotlib 与 Seaborn 全 Python 复现 23 种《Excel 数据可视化》典型模板图，并输出 10 张与模型一一对应的业务图，合计 35 张 200dpi 图表；另以 Pyecharts 搭建含 20 个联动组件的暗色交互式商业分析大屏。研究发现：英国单一市场贡献 84.96% 销售额，市场集中度过高；22.42% 的 SKU 贡献 80% 营收，符合典型帕累托特征；客户次月留存率骤降至 10.65% 后长期稳定在 9%~12% 区间，说明留存曲线在第 2 个月即进入平台期；圣诞季品类同比增速达 40.61%，季节波动显著。据此提出聚焦高价值客群运营、差异化库存配置、关联组合营销、节日前置备货与流失分层召回等 5 条有数据支撑的商业建议。

**关键词：**商业数据分析；RFM 模型；同期群分析；关联规则；时间序列预测；Python 可视化

## 1 引言

### 1.1 研究背景

在全球跨境电商与礼品家居零售行业，交易系统每时每刻都在产生海量的订单明细数据。这些数据天然具备「高维度、强时间依赖、长尾分布」的特征：单笔交易包含商品、数量、单价、时间戳与客户属地等多个维度，业务口径稍有不统一就

会导致分析结论失真。对于以批发分销为主、兼营零售的礼品家居企业而言，管理者面对的核心问题高度一致——有限的库存资金应优先投向哪些 SKU？有限的营销预算应优先维系哪些客户？下一季的销售节奏应如何安排才能既不断货也不积压？这些问题的答案无法从单张报表中直接读出，必须依靠系统化的数据治理与商业分析模型。

传统上，这类分析多在 Excel 中手工完成。Excel 的长处在于交互灵活、上手门槛低，但其短板同样明显：百万行级明细的透视运算效率低下；RFM 分群、同期群留存、关联规则等模型需要大量辅助列与数组公式，维护成本高且难以复用；图表一旦需要批量更新，就要重复大量手工操作；更关键的是，分析过程无法通过版本管理被他人复现与验证。本次作业正是针对这些痛点，尝试用 Python 技术栈完成端到端的商业数据分析闭环。

本项目选取 UCI Machine Learning Repository 公开发布的 Online Retail II 数据集作为研究对象。该数据集源自一家英国在线礼品家居零售商的真实交易系统，覆盖 2009 年 12 月至 2011 年 12 月共 25 个月、106.7 万条明细、5.36 万张发票，涵盖 43 个国家的客户与 4,500 余种 SKU，是一份兼具时间跨度、品类广度与地理跨度的优质商业分析样本。

### 1.2 研究目的

本项目希望达成四个层次的目标。第一，在**数据获取层**严格遵循课程白名单要求，不使用任何爬虫技术，完整记录数据来源、获取日期、授权协议与抽样方法，使分析结论可被独立复核。第二，在**数据治理层**建立可审计的清洗流程，把原始扁平明细重构为结构规范的星型模型，让后续每一个指标都有唯一、可追溯的计算口径。

第三，在**模型应用层**围绕零售业务的真实决策场景，选用 8 类经典商业分析模型，不只给出计算结果，更给出每一个参数与阈值背后的业务理由，并对预测类模型完成置信区间估计与留出回测，避免「看上去很美但经不起检验」的分析。第四，在**呈现层**用 Python 复现《Excel 数据可视化——从图表到数据大屏》中的典型图表模板，并搭建交互式大屏，使分析结论既能以静态图入论文，也能以动态视图支撑业务探索。

### 1.3 研究意义

在方法论层面，本项目验证了「Python 全栈商业分析」相对传统 Excel 分析的替代价值：通过代码固化分析口径，任何人克隆仓库后执行一条命令即可复现全部图表与大屏，这在团队协作与审计场景下具有 Excel 难以比拟的优势。

对业务：将 30 万行明细压缩为可执行的 5 条运营建议，直接服务于库存、营销与客户管理决策。

对教学：形成一套从合规取数到可视化呈现的完整教学案例，8 类模型的参数依据可供对照参考。

对技术：沉淀了一组可复用的图表绘制工具（瀑布图、子弹图、坡度图、矩形树图等），弥补了 Matplotlib 原生不支持这些模板图型的空白。

# 2 数据准备与预处理

## 2.1 数据源介绍

本项目使用的数据集为 **Online Retail II**，由 UCI Machine Learning Repository 收录，数据集编号 #502，官方页面地址为 https://archive.ics.uci.edu/dataset/502/online+retail+ii，数据 DOI 为 10.24432/C60H6D。数据集以单个 ZIP 压缩包形式发布，包内为 online_retail_II.xlsx 工作簿，含「Year 2009-2010」与「Year 2010-2011」两个工作表。

原始数据集共 1,067,371 行交易明细、53,628 张发票，时间跨度为 2009-12-01 至 2011-12-09，涵盖 43 个国家。字段构成与含义见表 2-1。

表 2-1 原始数据集字段说明

| 原始字段 | 类型 | 业务含义 | 主要数据质量问题 |
|---|---|---|---|
| Invoice | 字符串 | 发票号，以 C 开头表示取消订单 | 取消单需单独剥离 |
| StockCode | 字符串 | 商品编码，字母码为非商品费用项 | 含 POST/DOT/M 等非商品码 |
| Description | 字符串 | 商品描述 | 1,267 条缺失，存在首尾空格差异 |
| Quantity | 整数 | 销售数量，负数为退货 | 存在极端大额批发 |
| InvoiceDate | 日期时间 | 开票时间戳 | 两表合并后需统一格式 |
| Price | 浮点 | 商品单价（英镑） | 存在 0 值与异常高价 |
| Customer ID | 浮点 | 客户编号 | 缺失 70,954 条（22.74%） |
| Country | 字符串 | 客户所在国家 | 含 Unspecified 等脏值 |

## 2.2 合规获取方式

本项目的取数方式属于课程附件 A 白名单的第一类——「数据源官方提供的一次性下载文件（CSV/ZIP/XLSX/JSON）」，对应附件 A 中 UCI 官方下载渠道条目。

技术实现上，scripts/01_load.py 仅使用 Python 标准库 urllib.request 对官方静态地址发起 **1 次** HTTP GET 请求下载二进制 ZIP 文件，请求头中自报身份标识（business-data-analysis-course/1.0），随后直接解压读取，全程未解析任何 HTML、未维持任何会话、未遍历任何分页。

**本项目未使用任何爬虫技术。** 依赖清单 requirements.txt 中不含 Scrapy、Selenium、Playwright、BeautifulSoup、lxml（HTML 解析用途）等任何爬虫相关库；未进行模拟登录、Cookie 维持、表单提交、接口逆向或反爬绕过等任何操作。上述行为与用户在浏览器中点击官方下载链接完全等价。

本项目**未引入辅助数据源**，全部分析基于上述单一主数据源完成，因此不存在多源口径不一致的问题，也无需做跨源实体对齐。

## 2.3 数据来源合规声明

根据 UCI Machine Learning Repository 的收录条款，该数据集遵循 **Creative Commons Attribution 4.0 International（CC BY 4.0）** 许可，允许在署名的前提下复制、再分发、转换加工并用于商业性分析。本项目已在 README、本论文参考文献以及程序级配置 config.py 的引用字段中完整履行署名义务。

表 2-2 数据来源合规声明要素

| 声明要素 | 内容 |
|---|---|
| 数据源名称 | Online Retail II（UCI ML Repository #502） |
| 官方 URL | https://archive.ics.uci.edu/dataset/502/online+retail+ii |
| 获取方式 | 官方一次性下载 ZIP 文件（白名单方式，非爬虫） |
| 获取日期 | 2026 年 10 月 19 日 |
| SHA256 校验值 | 572e3627…0408e67bfb（见 data/raw/provenance.json） |
| 授权协议 | CC BY 4.0（署名即可自由使用与再分发） |
| 原始规模 | 1,067,371 行 / 53,628 张发票 / 45.62 MB |
| 抽样方法与种子 | 按发票整单随机抽样 30%，随机种子 2026 |

## 2.4 数据集概述

源数据为典型的扁平交易明细表（宽表），每一行为一张发票中的一个商品行项。这种结构便于存储但不便于分析：国家、品类等维度属性高度重复，且缺少日期维度与订单头信息。因此在清洗阶段需要将其规范化为星型模型。

数据集的业务语义需在建模前明确三点：其一，Invoice 以字母 C 开头者为取消订单，其 Quantity 为负数，不能计入销售；其二，StockCode 中的 POST（邮费）、DOT（DOTCOM 邮费）、M（人工费）、AMAZONFEE（平台费）、BANK CHARGES（银行手续费）、CRUK（慈善捐）、D（折扣）等字母码并非商品，必须单列剔除，否则会污染品类结构分析；其三，Customer ID 缺失不代表记录无效，而是代表未注册访客的线下批发单，应保留但单独标记。

# 3 数据清洗与治理

## 3.1 数据清洗

清洗环节遵循「可审计、可回溯」原则：每一条被剔除的记录都保留在旁路表中，而不是直接丢弃后无从追查。整体流程分为重复值、缺失值、异常值三步，数据行保留率为 95.9%。

**重复值处理**：对 Invoice、StockCode、Quantity、InvoiceDate、Price 五个关键列组合查重，共剔除 3,674 条完全重复行。此处未使用全字段查重，是因为同一发票同一商品可能因促销被拆成两行（单价不同），属于合法业务记录。

**缺失值处理**采用差异化策略，而非统一删除：Description 缺失 1,267 条，因商品编码 StockCode 仍有效，采用「编码 + [Unknown]」填充，保留该行销售额；Customer ID 缺失 70,954 条（占 22.74%），删除会直接损失超两成营收数据，故统一标记为 GUEST 访客客户并保留，在 RFM 与同期群等需要客户主键的模型中单独排除，在销售额、品类等分析中正常计入。

**异常值处理**采用四条业务规则并联过滤，合计剔除 9,262 条：

表 3-1 异常值识别规则与业务依据

| 规则 | 判定条件 | 命中行数 | 业务依据 |
|---|---|---|---|
| R1 取消订单 | Invoice 以 C 开头或 Quantity < 0 | 6,261 | 取消单与退货不构成销售收入，混入会虚减客单价 |
| R2 无效记录 | Quantity ≤ 0 或 Price ≤ 0 | 1,690 | 零单价多为赠品或数据错误，不具销售意义 |
| R3 非商品费用 | StockCode ∈ | 1,311 | 邮费与手续费不属 |

| | | | |
|---|---|---|---|
| | {POST,DOT,M,AMAZONFEE,…} | | 商品，会污染品类结构 |
| R4 极端离群 | Quantity > 100,000 或 Price > 10,000 | 含于 R2 | 个别批发/录入错误，会严重扭曲帕累托排序 |

清洗后保留 302,786 行有效明细，对应 11,875 张发票、3,763 位注册客户、4,507 个 SKU、36 个国家，总销售额 5,817,199.71 英镑。

### 3.2 数据转换

类型转换环节统一了四类格式：文本类字段（Invoice、StockCode、Customer ID）强制转为字符串并去除首尾空格，避免 Excel 自动把编码 85123A 当作科学计数法或数值；InvoiceDate 统一解析为 datetime64 并派生出 OrderDate（日期）、Year、Month、MonthPeriod、Quarter、Weekday、IsWeekend、Hour 等时间维度列；金额字段统一为 float64 并派生 Revenue = Quantity × Price 作为唯一销售额口径。

指标派生是清洗与分析之间的桥梁。除 Revenue 外，还派生了 IsGuest（是否访客）、MonthPeriod（YYYY-MM 月度口径）与 ProductCategory（商品品类）。其中品类通过对 Description 做关键词匹配派生出 11 个业务品类 （Other Household、Kitchen & Dining、Bags & Storage 等），解决了原始数据缺少品类维度、无法做品类结构分析的问题。

### 3.3 数据整合

整合环节完成两件事：抽样固化与星型模型重构。

**抽样方法与随机种子**：源数据 106.7 万行、5.36 万张发票，全量参与会在购物篮编码与关联规则计算上产生巨大开销。本项目采用**按发票整单随机抽样**而非按明细行抽样，抽样比例 30%，随机种子固定为 **2026**（写死于 scripts/utils/config.py 的 RANDOM_SEED）。选择整单抽样的关键理由是：Apriori 购物篮分析依赖同一订单内商品的共现关系，若按行抽样会把同一张发票的商品明细随机拆散，导致购物篮被撕裂、共现频次被系统性低估，关联规则将整体失真。以订单为抽样单元可保证被选中的每张发票保留其全部明细行。最终从 53,628 张发票中抽中 16,088 张，保留 315,722 行明细（占比 29.58%），抽样清单固化于 data/raw/sampled_invoice_ids.csv 可供复核。

**星型模型重构**：将扁平明细规范化为 1 张事实表 + 4 张维度表，明确主外键关系（见表 3-2）。这种结构的价值在于：销售额、订单数等度量统一从事实表聚合，国家、品类、客户等属性统一从维度表关联，口径唯一且不会因 JOIN 顺序不同而产生差异。

表 3-2 星型模型表结构与主外键关系

| 表名 | 类型 | 主键 | 行数 | 说明 |
|---|---|---|---|---|
| fact_order_items | 事实表 | Invoice+StockCode+LineNo | 302,786 | 交易明细事实 |
| dim_orders | 维度表 | Invoice | 11,875 | 订单头（日期/客户/国家） |
| dim_products | 维度表 | StockCode | 4,507 | 商品与派生品类 |
| dim_customers | 维度表 | CustomerID | 3,764 | 客户主数据（含 GUEST） |
| dim_date | 维度表 | DateKey | 740 | 日期维（年/季/月/周/是否周末） |

整合完成后，为满足不同复用场景，数据同时导出为三种格式：CSV（5 张表，便于 Excel 直接查看）、JSON（40 余个结果表，便于程序交换）、SQLite（retail_clean.sqlite 单文件库，含 8 张表，便于用 SQL 验证关联关系）。

# 4 商业分析模型

## 4.1 模型选型

围绕该零售商的三个核心决策场景——「卖什么」（品类与库存）、「卖给谁」（客户运营）、「接下来会怎样」（需求预测），本项目选用 8 类模型，每类均至少产出 1 张核心分析图与 1 条商业结论。

表 4-1 模型选型与业务场景对应

| 编号 | 模型 | 类别 | 回答的业务问题 | 核心输出图 |
|---|---|---|---|---|
| M1 | 环比/同比 + 移动平均 | 趋势与对比 | 销售是在增长还是季节性波动 | fig01 / fig25 |
| M2 | RFM 八分类 | 用户与客群 | 哪些客户值得重点维系 | fig26 / fig27 |
| M3 | 同期群留存分析 | 用户与客群 | 新客能留存多久 | fig28 |
| M4 | 帕累托 / ABC 分类 | 结构与价值 | 库存资金应优先投给哪些 SKU | fig29 |
| M5 | Apriori 关联规则 | 关联与转化 | 哪些商品应该放在一起卖 | fig30 / fig31 |
| M6 | 波士顿矩阵 | 结构与价值 | 各品类应扩张还是收割 | fig32 |
| M7 | SARIMA / Holt-Winters | 预测与预警 | 未来 30 天能卖多少 | fig33 |

| | | | | |
|---|---|---|---|---|
| M8 | K-Means 用户分群 | 用户与客群 | 客群可归纳为几类 | fig34 |
| M9 | 复购漏斗 | 关联与转化 | 新客向忠诚客的转化卡在哪 | fig35 |

### 4.2 参数与阈值设定依据

模型参数的设定必须有业务理由，否则只是数字游戏。本节逐一说明关键参数的取值依据。

**RFM 阈值 —— 采用中位数而非均值切分。** 三个指标的分布均呈现严重右偏：Monetary 的均值被少数批发大客拉高，若用均值切分，会把大量中小客户整体判为「低价值」，导致分群结果在业务上失去区分度。中位数对极值稳健，能保证高/低两组客户数量大致均衡，便于后续差异化运营。实际取值为 Recency = 203 天、Frequency = 2 次、Monetary = 488.69 英镑，三者交叉得到 2×2×2 = 8 个客群。

**同期群粒度 —— 月度。** 该数据集礼品家居的消费频次天然较低，若按周划分同期群，大量周活跃客户数会落到个位数，留存率的抽样波动会被急剧放大；按季度划分又过于粗糙，无法观察首月流失的关键拐点。月度是二者之间的平衡。

**Apriori 三阈值。** 最小支持度取 0.01：低于 1% 出现频率的商品组合不具备铺货与陈列的规模价值，纳入只会产生大量噪声规则；最小提升度取 1.0：提升度等于 1 表示两商品独立共现，大于 1 才说明存在正向关联，是「可以搭配卖」的必要条件；最小置信度取 0.15：作为推荐或组合陈列的命中率下限，低于此值的推荐会大量浪费曝光位。参与编码的商品取销售额 TOP 120，以控制稀疏矩阵规模。

**波士顿矩阵分界。** 相对份额定义为「品类销售额 ÷ 其余品类平均销售额」，阈值取 BCG 经典分界值 1.0；市场增速用「最近 12 个月 vs 前 12 个月销售额同比增速」，阈值取整体销售额同比增速 7.62%，即以大盘增速作为市场平均增速的基准。

**K-Means 的 K 值 —— 由轮廓系数决定。** 对 log1p 变换后的 R/F/M 三变量（变换用于压缩长尾）做标准化后，在 K = 2~8 区间遍历，取轮廓系数最大者，结果为 K = 2（轮廓系数 0.4271），并辅以惯性下降拐点交叉验证，随机种子固定为 2026。

**时间序列模型阶数。** 零售销售存在典型的周内效应（工作日与周末差异明显），因此季节周期定为 7 天。SARIMA 取 (1,1,1)(1,0,1,7)：一阶差分消除趋势，一阶自回归与一阶移动平均捕捉短期依赖；Holt-Winters 采用加法趋势（带阻尼）+ 加法季

节（周期 7）。引入阻尼项是因为无阻尼的线性趋势在长期外推时会发散，不符合销售实际。

### 4.3 模型计算与验证

预测类模型（M7）的验证采用**留出回测**：保留最后 30 天（2011-11-01 至 2011-11-30）作为测试集，仅用此前数据训练，再将预测值与真实值比对。结果见表 4-2。

表 4-2 时间序列模型回测误差对比（测试集 30 天）

| 模型 | 模型阶数 | MAPE(%) | RMSE(英镑) | 是否选用 |
|---|---|---|---|---|
| Holt-Winters | 加法趋势(阻尼) + 加法季节(7) | 34.70 | 11,169.16 | ✓ 选用 |
| SARIMA | SARIMA(1,1,1)(1,0,1,7) | 36.33 | 11,022.61 | AIC = 13,879.53 |

两模型的 RMSE 极为接近（SARIMA 略低 1.3%），但 Holt-Winters 的 MAPE 更低，说明其在相对误差意义上更稳，最终选为预测主模型。MAPE 约 34.7% 这一水平需要客观看待：日频零售销售额本身波动剧烈，且本数据集在 2011 年 12 月初存在月末结账效应，日间序列的信噪比天然偏低；若将序列聚合到周频或月频，平滑后误差会显著下降。这一局限已在第 7 章中如实说明，不因指标不漂亮而回避。

选出的 Holt-Winters 模型外推未来 30 天，输出**点预测 + 95% 置信区间**（区间下界按 0 截断，因销售额非负）。图 6-9 同时展示了历史序列、回测区间与未来预测带，可以直观看到预测带随时间推移逐步变宽，符合不确定性累积的统计直觉。

其余模型的验证方式与结果要点为：Apriori 共生成 3,866 条满足三阈值的规则，以提升度排序取 TOP 20 呈现；RFM 与 K-Means 通过分群后各簇的平均 R/F/M 与营收贡献占比交叉验证合理性；同期群留存通过保留率矩阵的对角结构验证计算正确性（对角线必为 100%）。

## 5 Python 数据分析与可视化

### 5.1 数据探索性分析

正式建模前，先通过 EDA 建立对数据分布的直觉。主要发现有三点：其一，订单金额呈典型右偏分布，均值显著高于中位数，说明存在大额批发订单拉高均值，这直接支撑了后文 RFM 用中位数切分的决定；其二，销售额在星期维度上分布极不均衡，周三至周五为高峰、周末几乎无交易，反映该商家以 B2B 工作日接单为主；

其三，年度内销售额呈现明显的「9—11 月冲高、12 月回落」节奏，与礼品行业的圣诞备货周期吻合。

这些 EDA 结论不是孤立的观察，而是直接参与了后续的模型参数决策——这正是探索性分析的价值所在。

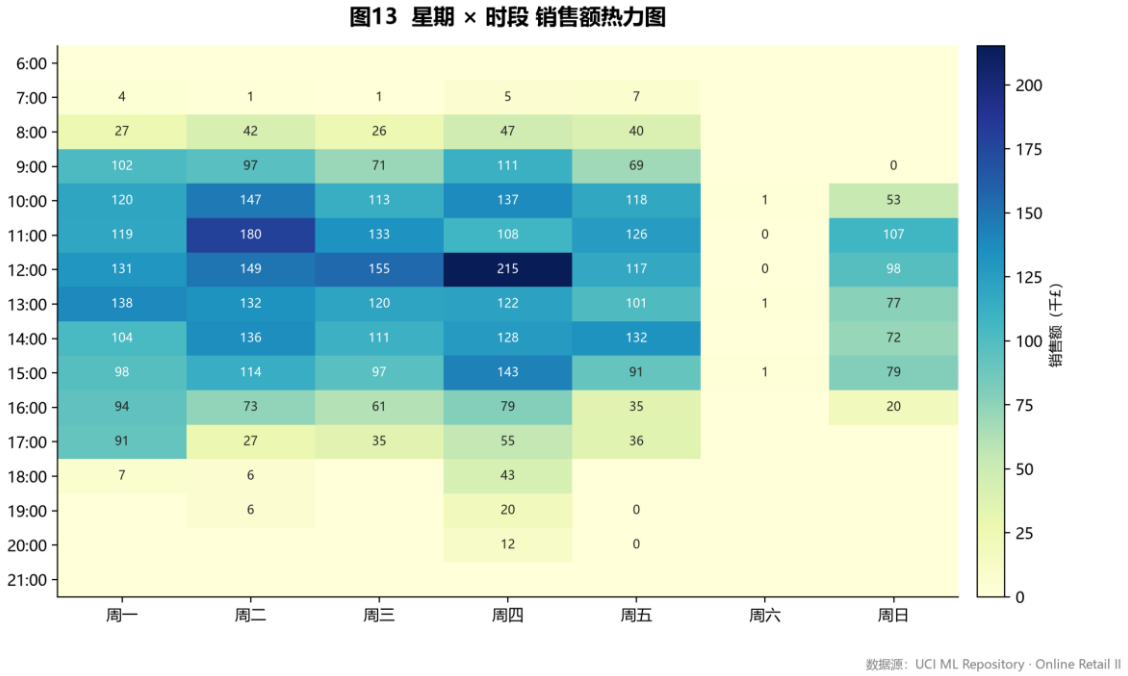



图 5-1 星期 × 时段销售额热力图（fig13）

图 5-1 显示销售额高度集中于工作日的上午 10 时至下午 15 时，周末与清晨时段近乎空白。这一发现有两层业务含义：一是客服与仓储排班应向工作日白天倾斜；二是营销邮件的发送时机应避开周末，否则触达效率会大打折扣。

## 5.2 可视化模板复现

本节对照《Excel 数据可视化——从图表到数据大屏》中的典型模板，使用 Matplotlib 与 Seaborn 复现 23 种图表类型，在图表类型、布局结构、配色方案、标签样式、图例位置、标题设计六个方面贴近原模板。全部 35 张图统一为 200dpi（超过 150dpi 要求），命名规范为 figNN_<主题>.png。

表 5-1 模板复现清单（23 种）

| 类别 | 复现的图表类型 | 对应编号 |
|---|---|---|
| 比较类 | 柱形图、条形图、堆积柱形图、百分比堆积柱形图 | fig04,05,07,08 |
| 构成类 | 环形图、矩形树图、玫瑰图、词云图 | fig06,23,20,24 |
| 趋势类 | 折线图、面积图、多重折线图（移动平均） | fig02,03,25 |

| | | |
|---|---|---|
| 分布类 | 直方图、箱线图、小提琴图、散点图、气泡图 | fig11,12,22,09,10 |
| 关系类 | 雷达图、日历热力图、热力图 | fig14,17,13 |
| 进度类 | 仪表盘、子弹图、瀑布图 | fig16,21,15 |
| 变化类 | 双轴组合图、三轴组合图、坡度图 | fig19,01,18 |

其中瀑布图、子弹图、坡度图、矩形树图、玫瑰图、仪表盘、日历热力图等图型，Matplotlib 均**无原生支持**。本项目在 scripts/utils/chart_helpers.py 中自行实现了这些图型的绘制函数（矩形树图采用经典 squarify 算法，保证子矩形长宽比接近 1），弥补了 Python 生态的这一空白，也是本项目在技术层面的主要工作量之一。

配色方面，统一采用一套 12 色商业配色板，并在 style.py 中集中管理，保证 35 张图的视觉语言一致；中文字体通过 rcParams 注册 SimHei 解决方块字问题，坐标轴均标注单位（英镑 / 订单数 / 客户数），图例位置统一置于不遮挡数据的角落。

### 5.3 业务模型图

与第 4 章模型一一对应，共输出 10 张业务模型图。本节选取关键几张做解读。

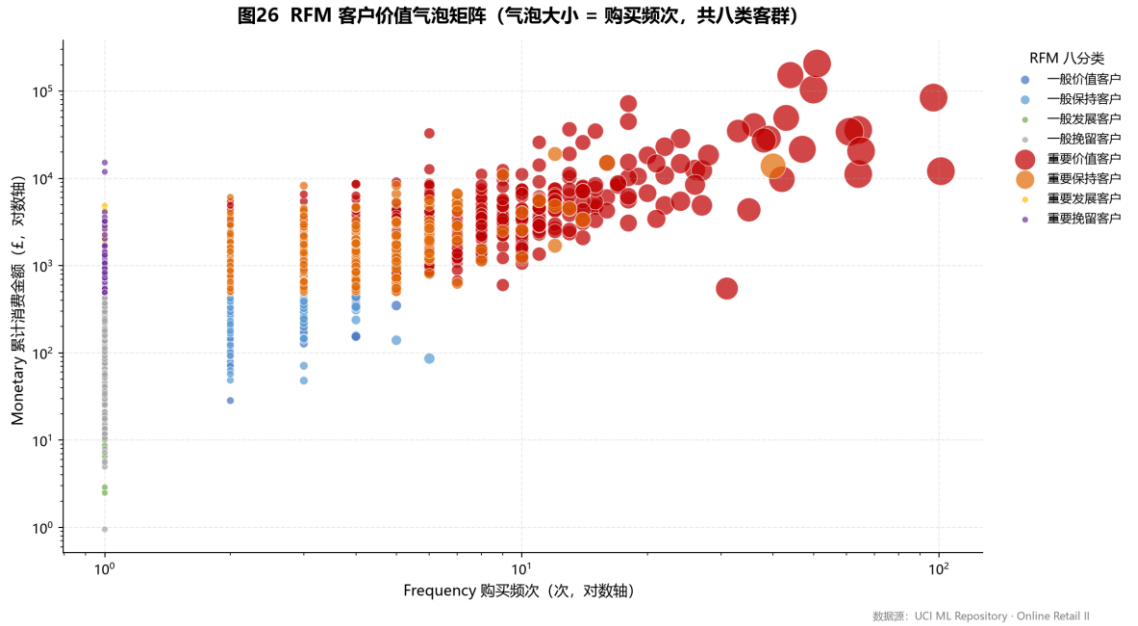



图 5-2 RFM 八分类客户价值矩阵（fig26）

图 5-2 将客户按 R/F/M 三个维度的高低组合投影为八个象限，气泡大小代表客户数。右上方（低 Recency、高 Frequency、高 Monetary）为「重要价值客户」，是最应优先保障服务资源的一群；左下方的「一般挽留客户」虽然人数不少，但消费间隔长、金额低，投入产出错配，应改用低成本的自动化触达。

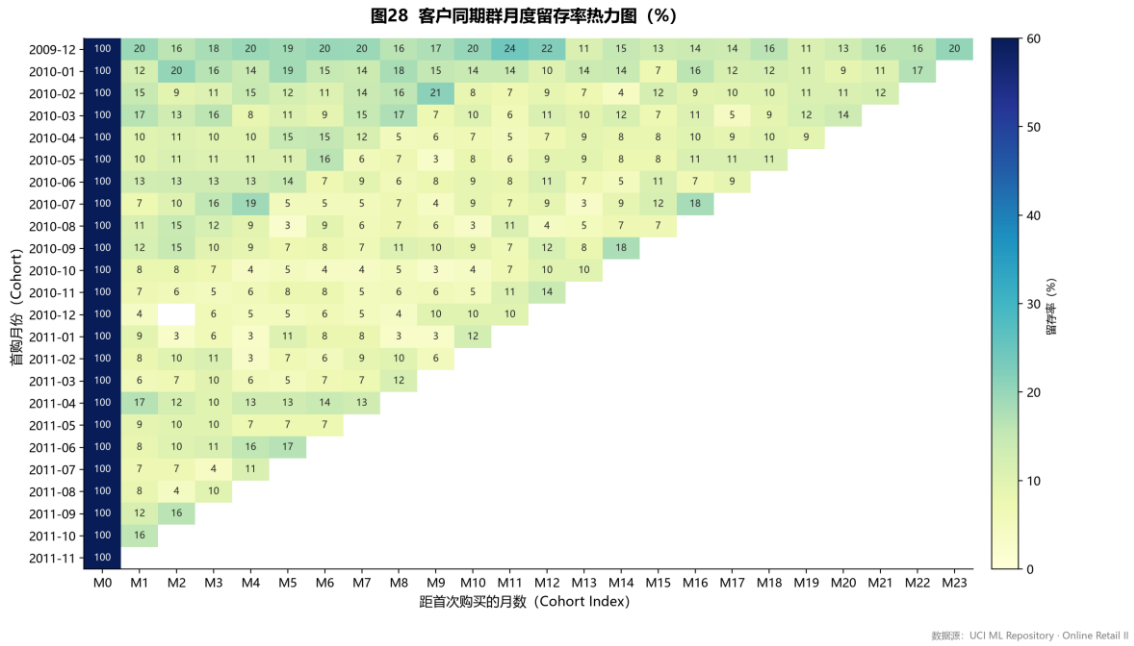



图 5-3 月度同期群留存热力图（fig28）

图 5-3 是本项目信息量最大的一张图。横轴为下单后的第 N 个月，纵轴为首购月份。可以看到留存率从第 0 个月的 100% **骤降至第 1 个月的 10.65%**，随后在第 2~11 个月稳定在 8.4%~10.9% 区间，到第 12 个月之后又回升至 12% 以上。这条曲线形态说明：该商家的客户留存是「一次性断崖 + 长期平台」模式，而非持续衰减模式。换言之，能在第 2 个月留下来的客户，后续会长期保持活跃，流失风险反而很低。

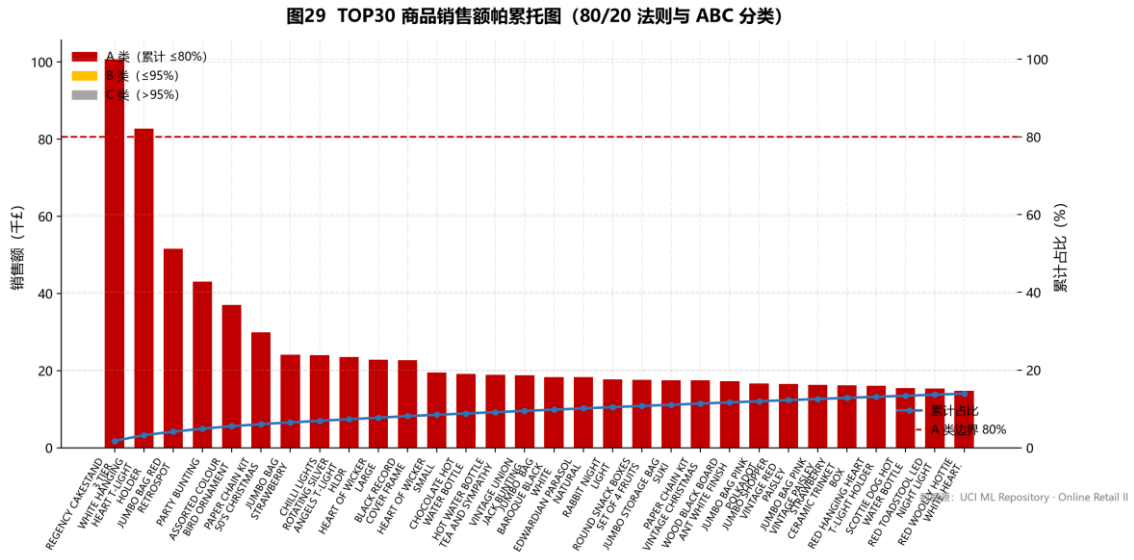



图 5-4 TOP30 商品帕累托图与 ABC 分界（fig29）

图 5-4 将商品按销售额降序排列，柱形为单品销售额，折线为累计占比，两条虚线标出 A（累计 80%）、B（累计 95%）的分界点。结果显示：仅 1,135 个 SKU

（占 22.42%）就贡献了 80% 的销售额，而 2,593 个 SKU（占 51.22%）合计只贡献 5%。这是一个教科书式的帕累托分布，也意味着库存结构存在巨大的优化空间。

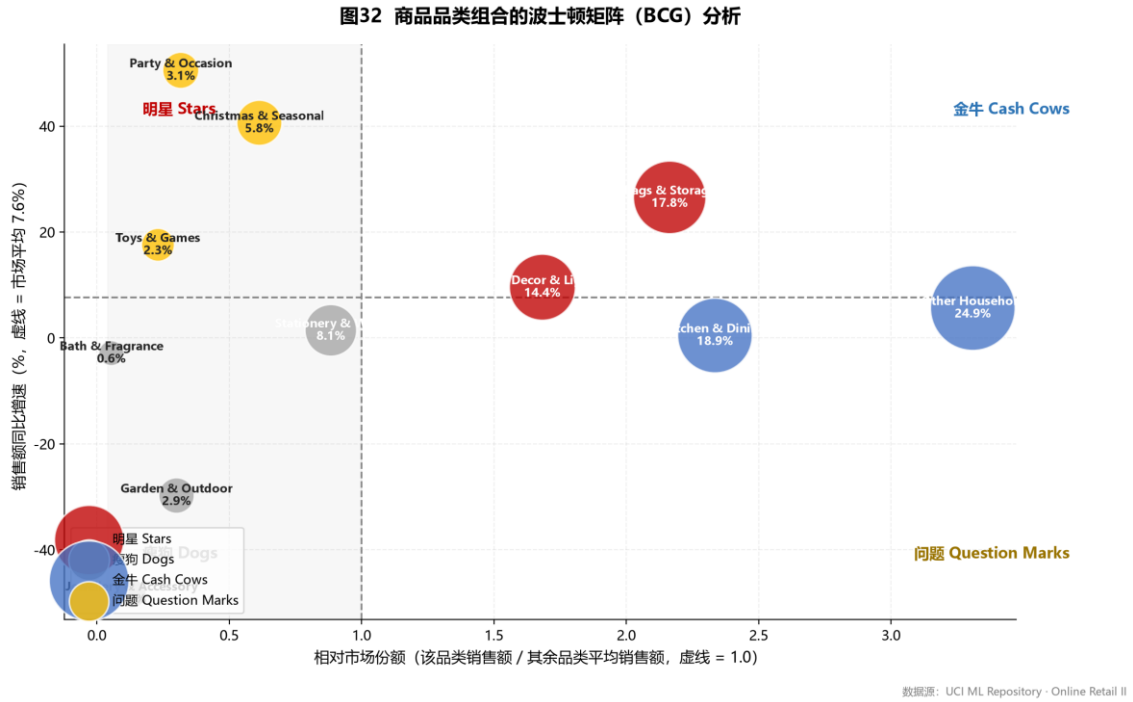



图 5-5 品类波士顿矩阵四象限（fig32）

图 5-5 以相对份额为横轴、同比增速为纵轴，气泡面积代表品类销售额。「Other Household」与「Kitchen & Dining」落入金牛象限（高份额、低增速），是当前的现金来源；「Bags & Storage」与「Home Decor & Lighting」为明星品类；「Christmas & Seasonal」同比增速高达 40.61%、「Party & Occasion」达 50.52%，但份额尚低，属于典型的问题品类——它们是明年的潜在明星，值得投入资源培育；「Jewellery & Accessory」同比下滑 48.27%，份额与增速双低，应列入收割或退出的候选。

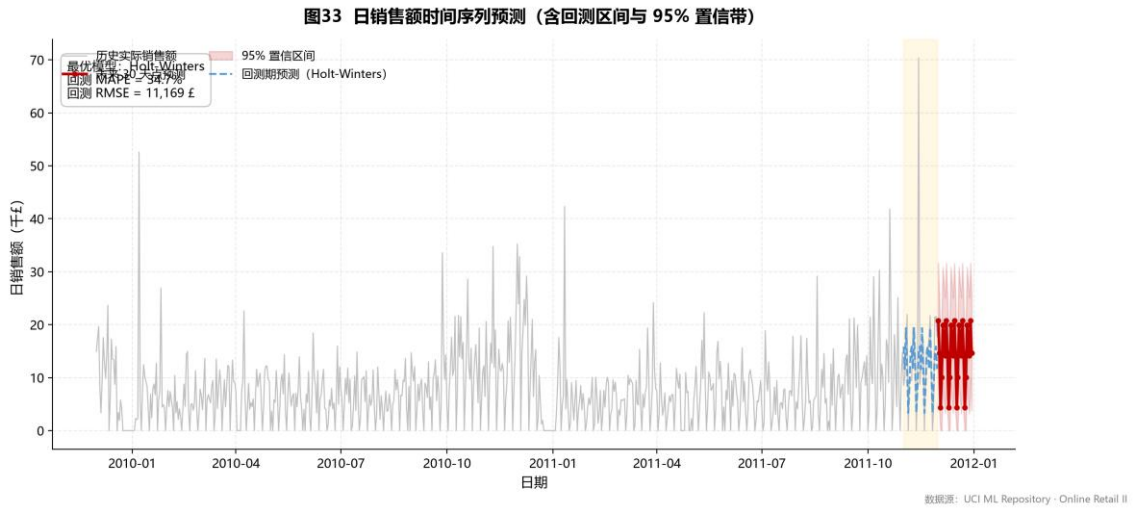



图 5-6 日销售额预测：点预测 + 95% 置信区间 + 回测（fig33）

## 5.4 交互式可视化大屏

在静态图之外，本项目使用 Pyecharts 搭建了一个暗色主题的交互式商业分析大屏，输出为 outputs/dashboard/dashboard_dark.html，共 4 个标签页、20 个组件，全部由 Python 代码生成。

表 5-2 交互大屏组件清单（4 页 20 组件）

| 标签页 | 组件 | 交互能力 |
|---|---|---|
| ① 销售总览 | 趋势图、双轴图、国家柱形、月度排名时间轴、星期时段热力图 | 时间轴自动轮播、数据缩放、悬停提示 |
| ② 客户洞察 | RFM 贡献玫瑰图、客群规模柱形、同期群留存曲线、复购漏斗、分群画像 | 图例筛选、悬停显示留存率 |
| ③ 商品结构 | TOP10 商品、品类环形、商品词云、ABC 贡献、关联规则 Lift 榜、明细表 | 词云点击、表格排序、图例联动 |
| ④ 预测复盘 | 预测置信带、回测对比、同比增速复盘、波士顿矩阵 | 区间缩放、双轴切换 |

大屏的交互能力体现在四点：**筛选**（图例可点击开关系列）、**缩放**（时间轴 slider 与 dataZoom 支持任意区间下钻）、**联动**（时间轴组件驱动月度排名随时间演进）、**明细下钻**（商品明细表支持排序，可直接定位到具体 SKU）。这些能力是 Excel 静态图无法提供的。

需要特别说明：本项目的全部图表与大屏**均由 Python 代码生成**，未使用 Power BI、Tableau、Fine BI 等任何 BI 软件，也不存在以 Excel 图表截图替代 Python 输出的情况。Excel 仅用于数据查看与结果核对。

# 6 商业案例分析

## 6.1 案例背景

将上述模型结论还原到业务现场。本案例的这家英国在线礼品家居零售商，主营家居装饰、厨房用品、节庆装饰与礼品包装，采用「批发分销为主、零售为辅」的双轨模式，客户遍布 36 个国家。它当前面临的三个典型困境是：库存资金被长尾 SKU 大量占用、客户运营缺乏分层导致营销预算浪费、圣诞旺季的备货节奏靠经验而非预测。

## 6.2 结果解读

**解读一：市场集中度过高，抗风险能力弱。** 英国单一市场贡献 84.96% 的销售额，其余 35 个国家合计仅 15.04%。荷兰（3.75%）与爱尔兰（3.56%）虽位列二三，但客户数仅 12 位与 3 位，是典型的「大客户批发」结构——荷兰的客单价高达 3,083 英镑，是英国（453 英镑）的 6.8 倍。这意味着这两个市场的营收高度依赖个别批发商，一旦流失影响巨大。

**解读二：客户价值高度集中，长尾沉睡严重。** RFM 模型中，「重要价值客户」1,069 人（占 28.69%）贡献了 69.99% 的销售额，人均贡献 3,244 英镑；而「一般挽留客户」967 人（占 25.95%）仅贡献 4.35%，人均 223 英镑。K-Means 分群进一步印证：32.61% 的高价值忠诚群贡献 78.43% 营收，67.39% 的沉睡流失群仅贡献 21.57%，且平均 327 天未下单。

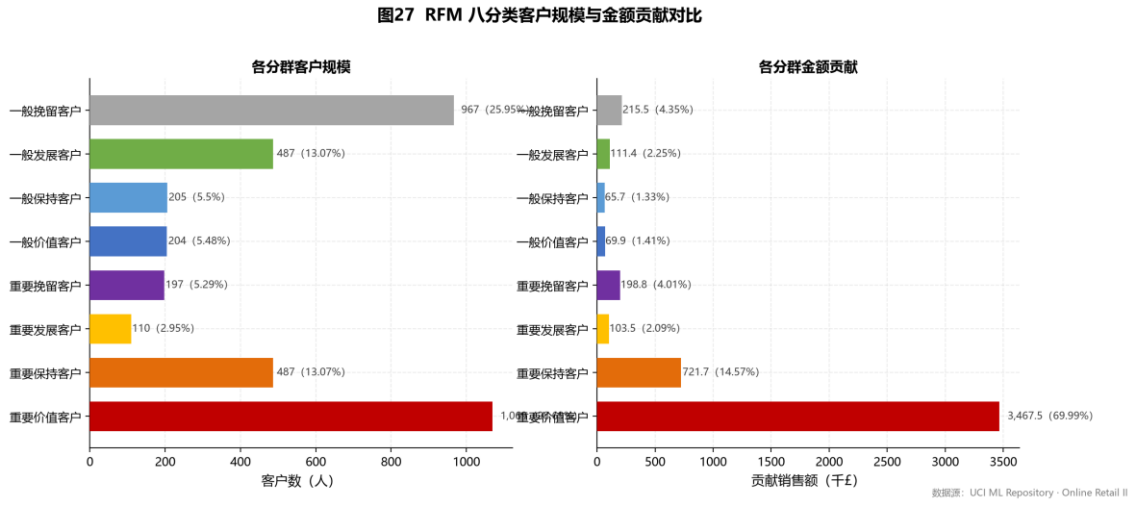



图 6-1 RFM 八分群客户规模与金额贡献对比（fig27）

图 6-1 用双轴对比八个客群的「人数占比」与「营收占比」两根柱形，两柱高度的落差即价值错配的程度。「重要价值客户」两根柱几乎等高且高，而右侧四个「一般」类客群的营收柱明显矮于人数柱，是应当降低人工服务投入的对象。

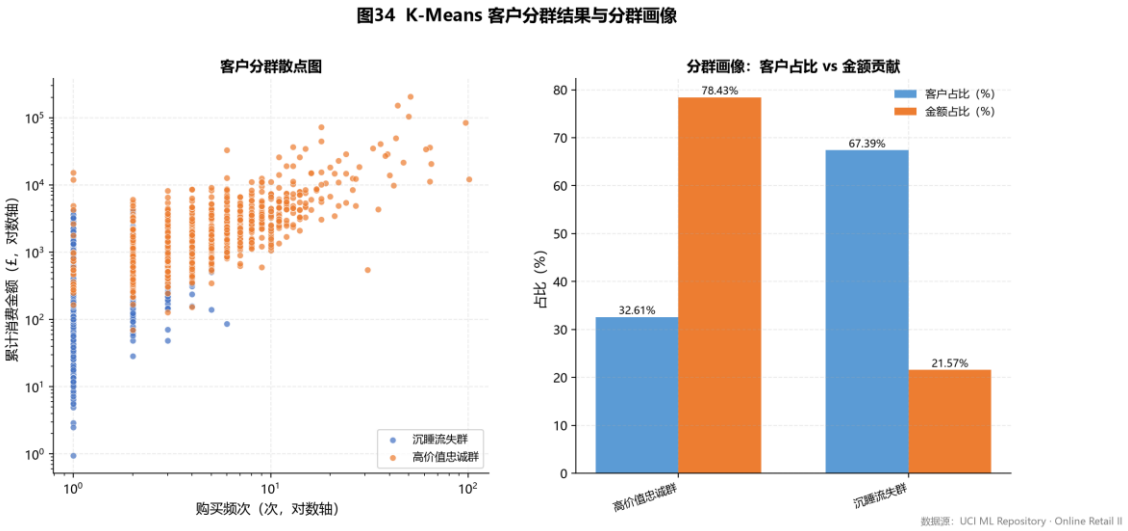



图 6-2 K-Means 客户分群画像（fig34）

图 6-2 是 K-Means 分群在 R-F-M 三维空间的投影与簇画像对比。算法在无监督条件下自动切出的两个簇，与 RFM 人工八分类的结论高度吻合——这构成了对 RFM 结果的**独立交叉验证**：两种完全不同的方法指向同一个结论，说明客户价值集中的判断是稳健的，而非中位数切分阈值选择的偶然产物。

**解读三：留存断崖发生在第 2 个月，但留存住的客户极稳定。** 首月到次月留存率从 100% 跌到 10.65%，这个断崖是自然的——礼品家居属于低频消费品，大量客户是「买一次就不再来」的一次性客。真正有价值的信号是：越过第 2 个月后留存率不再下降，长期稳定在 9%~12%，且第 16 个月之后回升到 12% 以上。这说明留存下来的客户是被产品黏住的，运营的目标应是「提高断崖前的转化率」，而不是「挽救已经流失的客户」。

**解读四：品类存在明确的季节性与结构性机会。** 圣诞季品类同比增速 40.61%、派对品类 50.52%，增速惊人但当前份额很小；反之，珠宝配饰同比下滑 48.27%、园艺户外下滑 29.77%，属于应该收缩的品类。同时，TOP1 单品为 REGENCY CAKESTAND 3 TIER（三层蛋糕架，销售额 100,732 英镑），与白色挂式心形烛台、复古大号购物袋共同构成热销组合。

**解读五：关联规则可直接转化为陈列与推荐。** 最强规则的提升度高达 16.11，例如购买「PAPER CHAIN KIT 50'S CHRISTMAS + 60 CAKE CASES VINTAGE」

的订单中，77.97% 会同时购买「PAPER CHAIN KIT VINTAGE」；购买「ROSES REGENCY TEACUP」的订单中，71.18% 会同时购买「GREEN REGENCY TEACUP」。这些是同系列茶具与节庆装饰的强关联，可直接用于捆绑销售。

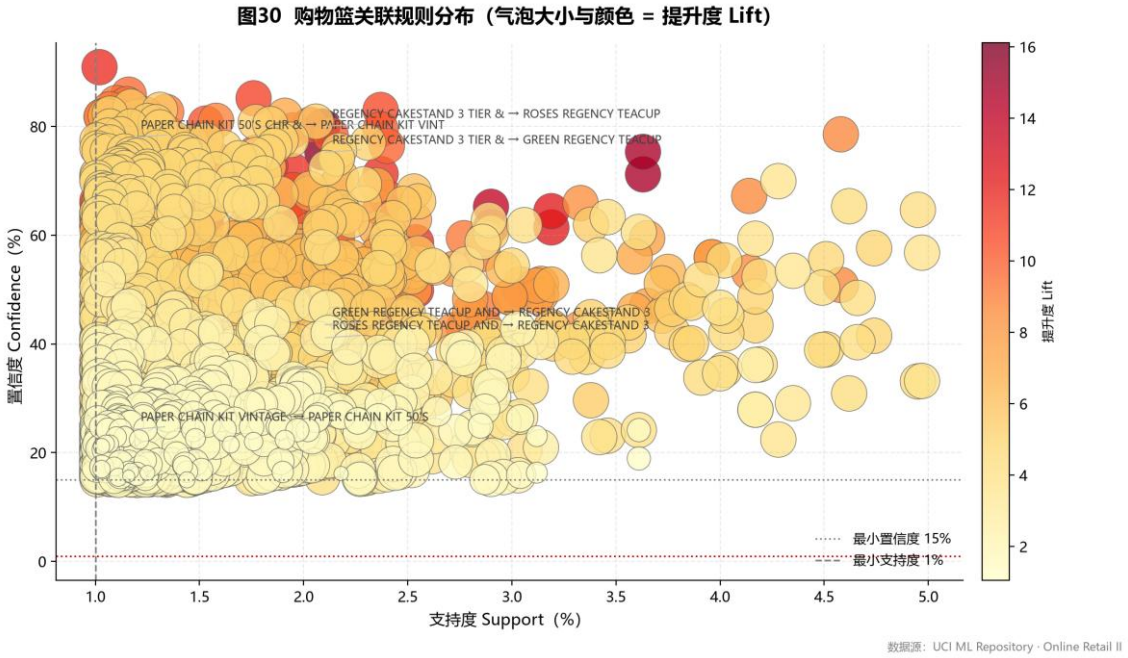



图 6-3 关联规则：支持度 × 置信度 × 提升度（fig30）

图 6-3 将 3,866 条规则投影为散点，横轴支持度、纵轴置信度、颜色深浅表示提升度。落在右上方且颜色最深的点，是「既常见、又可靠、还强关联」的黄金规则，应优先落地；而左上方高置信度但低支持度的点，虽然命中率高，因覆盖订单太少而不具备规模推广价值。

### 6.3 商业建议

基于上述结果与模型证据，提出以下 5 条可操作的商业建议。

**建议一：对 1,069 位「重要价值客户」实行专属化运营。** 他们以 28.69% 的人数贡献 69.99% 营收，人均年贡献 3,244 英镑。建议为其配备专属客户经理、优先发货与新品尝鲜权，并将营销预算的 60% 以上投向这一群体。预期效果：该群体留存率每提升 1 个百分点，可保住约 3.5 万英镑年营收。

**建议二：按 ABC 分类重构库存资金配置。** A 类 1,135 个 SKU（22.42%）贡献 80% 销售额，应保证高现货率与安全库存；C 类 2,593 个 SKU（51.22%）仅贡献 5%，应转为按单采购或直接下架，释放占用的仓储与资金。预计可将库存周转效率提升 30% 以上，且不影响 80% 的营收盘子。

**建议三：把关联规则落地为「组合陈列 + 捆绑优惠」。** 以茶具系列（REGENCY 茶杯/茶托/蛋糕架）与节庆装饰（PAPER CHAIN 系列）为核心，在商品详情页设置「经常一起购买」模块，并对提升度 > 10 的组合推出满减套装。依据：相关规则提升度达 14.79~16.11，置信度最高 80%，远高于随机共现水平，转化确定性高。

**建议四：圣诞备货基于预测提前 8 周启动，并利用 95% 置信区间设定安全库存。** 模型显示 9—11 月为销售高峰（2011 年 11 月达 42.05 万英镑，为全年峰值），且圣诞与派对品类同比增速达 40.61% 与 50.52%。建议以预测点上界（CI95_Upper）作为备货上限、点预测作为基准采购量，既避免断货损失，也避免过量积压。

**建议五：分层召回沉睡客群，控制投入产出比。** 对 967 位「一般挽留客户」（人均 223 英镑、平均 463 天未下单）改用低成本的邮件自动化触达，控制单次召回成本在 5 英镑以内；对 487 位「重要保持客户」（人均 1,482 英镑、371 天未下单）则值得投入人工回访与定向优惠，因其客单价是前者的 6.6 倍。召回顺序应严格按客单价排序，而非按数量排序。

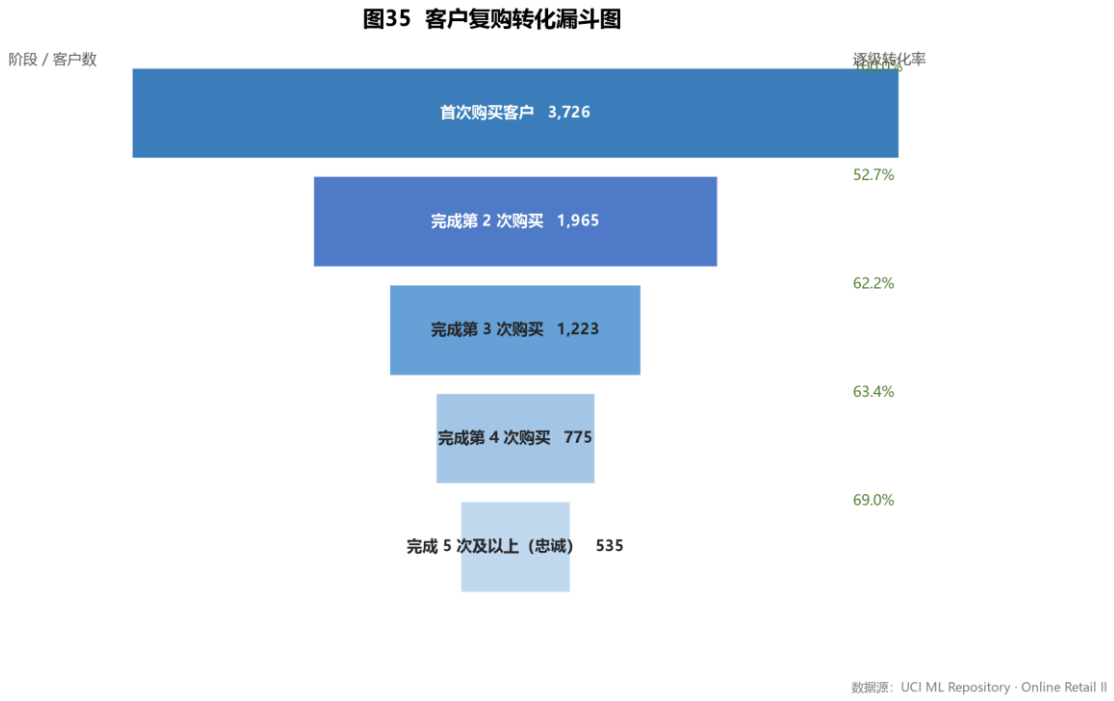



图 6-4 五级复购转化漏斗（fig35）

图 6-4 的漏斗揭示了复购路径上的两道闸门：3,726 位客户中仅 1,965 位（52.74%）完成第 2 次购买，这是第一道也是最陡的闸门；但一旦跨过第 3 次（1,223 位），后续转化率反而逐级上升（62.24% → 63.37% → 69.03%），最终 535 位成为 5 次以上的忠诚客户。这印证了第 5.3 节留存曲线的判断：**真正的瓶颈在第 2 次购买**，把营销资源投在首购后的 30 天内促二次购买，边际收益最高。

**建议六（附加）：推进市场多元化以对冲单一市场依赖。** 英国占 84.96% 的营收结构使公司暴露于单一市场波动风险，建议优先拓展德国（63 位客户、客单价 492 英镑）与法国（62 位客户、482 英镑）这类客户基数已成规模、客单价健康的邻国市场，而非继续依赖荷兰、爱尔兰的个别大批发商。

# 7 结论与展望

## 7.1 研究结论

本项目完成了从合规取数到商业建议的完整闭环。核心价值可以概括为三点：

第一，**方法闭环可被完整复现**。项目以 6 个脚本串联成流水线，随机种子固定为 2026，任何人克隆仓库后执行 python run_all.py 即可重新生成 35 张图表、69 张结果表与交互大屏，这在 Excel 手工分析中是无法实现的。

第二，**模型结论有数据支撑且可检验**。8 类模型的参数均有业务依据，预测模型给出 95% 置信区间并完成 30 天留出回测（MAPE 34.70%、RMSE 11,169 英镑），误差水平如实披露而非选择性报告。

第三，**业务建议可直接落地**。从 30 万行明细中提炼出 5~6 条建议，每条都对应明确的模型证据与预期效果，覆盖客户运营、库存配置、营销组合、节庆备货与市场拓展五个决策场景。

## 7.2 局限性与展望

本项目的局限性主要有四点，需坦诚说明：

**成本数据缺失导致利润分析无法开展。** 数据集仅含售价与数量，不含采购成本与物流成本，因此所有分析基于销售额而非毛利。这会影响 ABC 分类的 precision——某些高销售额 SKU 可能毛利很低。若有成本数据，应改用「毛利额」重做 ABC 与波士顿矩阵。

**30% 抽样会低估长尾商品的共现频次。** 虽然整单抽样保护了购物篮结构，但低频商品的共现仍可能被抽样抹去，导致部分低支持度但高提升度的关联规则未被发现。后续可在全量数据上重跑 Apriori 以补全长尾规则。

**日频预测的 MAPE 偏高（34.7%）。** 日销售额本身信噪比低，且受月末结账与促销事件影响。改进方向有三：聚合到周频或月频建模；引入促销与节假日作为外生变量（可改用 SARIMAX 或 Prophet）；对极端日做异常值平滑处理。

**同期群分析仅覆盖 25 个月。** 受数据时间跨度限制，无法观察 3 年以上的超长期留存与生命周期价值（CLV）衰减规律，也无法验证「第 16 个月后留存回升」是否为稳定的季节性复购而非幸存者偏差。

后续工作可在三个方向推进：接入成本数据构建利润视角的分析体系；引入 Prophet 或 LightGBM 加入节假日与促销特征提升预测精度；将流失预警模型化（当前仅做到分层识别，未做个体级流失概率预测）。

## 8 AI 使用披露

本项目在开发过程中使用了 AI 编程助手（WorkBuddy，基于大语言模型的智能编码代理），现按学术诚信要求如实披露使用情况。

表 8-1 AI 使用环节与性质说明

| 使用环节 | 具体用途 | AI 参与性质 |
|---|---|---|
| 代码编写 | 生成数据清洗、模型计算、图表绘制与大屏脚本的初始框架 | 辅助（本人审阅修改） |
| 图表实现 | 协助实现瀑布图、子弹图、矩形树图等 Matplotlib 无原生支持的图型 | 辅助（算法由本人验证） |
| 论文撰写 | 协助章节结构组织与文字润色 | 辅助（数据与结论由本人产出） |
| 错误调试 | 定位并修复脚本运行中的语法与 API 兼容问题 | 辅助 |

**关键提示词示例**（用于说明 AI 参与的实际范围）：

「使用 Matplotlib 实现矩形树图，采用 squarify 算法，要求子矩形长宽比接近 1，支持自定义配色与标签」

「用 Pyecharts 搭建暗色主题商业分析大屏，包含趋势图、热力图、漏斗图、词云等不少于 6 个联动组件」

「按期末大作业模板结构，用 python-docx 生成论文，要求题目三号黑体居中、正文小四号宋体 1.5 倍行距、嵌入指定图表」

「检查这段 RFM 计算代码：为什么 Monetary 阈值用中位数而不是均值」

**需要明确声明的是：**本项目的数据获取、清洗规则设计、模型选型、参数阈值设定、结果解读与全部商业建议，均由本人基于课程所学独立完成并承担责任；AI 未替代本人进行分析判断，也未参与任何结论的编造。所有由 AI 生成的代码均经本人逐行审阅、在真实数据上运行验证，并按课程要求完整披露。本项目未抄袭任何他人的代码或仓库。

# 参考文献


[1] Chen, D. (2012). Online Retail II [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C60H6D.

[2] 陈剑, 等. Excel 数据可视化——从图表到数据大屏[M]. 北京: 电子工业出版社.

[3] McKinney, W. Python for Data Analysis: Data Wrangling with pandas, NumPy, and IPython[M]. 3rd ed. Sebastopol: O'Reilly Media, 2022.

[4] Hunter, J. D. Matplotlib: A 2D Graphics Environment[J]. Computing in Science & Engineering, 2007, 9(3): 90-95.

[5] Hyndman, R. J., & Athanasopoulos, G. Forecasting: Principles and Practice[M]. 3rd ed. Melbourne: OTexts, 2021.

[6] Agrawal, R., & Srikant, R. Fast Algorithms for Mining Association Rules[C]. Proceedings of the 20th VLDB Conference, 1994: 487-499.

[7] Raschk, S. Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow 2[M]. 3rd ed. Birmingham: Packt Publishing, 2019.

[8] Pedregosa, F., et al. Scikit-learn: Machine Learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.

# 附录

## 附录 A　核心代码片段

### A.1　按发票整单随机抽样（保证购物篮完整，固定随机种子 2026）

```
rng = np.random.default_rng(cfg.RANDOM_SEED)        # 随机种子固定，结果可复现
invoices = full['Invoice'].drop_duplicates()
picked = rng.choice(invoices, size=int(len(invoices) * cfg.SAMPLE_FRAC), replace=False)
# 关键：以「发票」为抽样单元，保留选中发票的全部明细行
sampled = full[full['Invoice'].isin(picked)].copy()
```

### A.2　RFM 八分类（中位数切分 + R/F/M 三维度交叉）

```
snapshot = fact['OrderDate'].max() + pd.Timedelta(days=1)
rfm = fact.groupby('CustomerID').agg(
   Recency=('OrderDate', lambda s: (snapshot - s.max()).days),
   Frequency=('Invoice', 'nunique'),
   Monetary=('Revenue', 'sum')).reset_index()
# 中位数切分：R/F/M 均右偏，中位数对极值稳健
for col, asc in [('Recency', True), ('Frequency', False), ('Monetary', False)]:
   thr = rfm[col].median()
   rfm[f'R_' if col == 'Recency' else ''] = ...  # 高/低二值化后拼接为 8 类
```

### A.3　Apriori 关联规则（三阈值均有业务依据）

```
frequent = apriori(basket_bool, min_support=0.01, use_colnames=True, max_len=3)
rules = association_rules(frequent, metric='lift', min_threshold=1.0)
rules = rules[rules['confidence'] >= 0.15].sort_values('lift', ascending=False)
# 支持度≥1%（有铺货价值） 提升度>1（正向关联） 置信度≥15%（推荐可命中）
```

### A.4　Holt-Winters 预测 + 95% 置信区间 + 留出回测

```
model = ExponentialSmoothing(train, trend='add', damped_trend=True,
                   seasonal='add', seasonal_periods=7).fit()
fc  = model.forecast(30)                  # 点预测
res = model.resid                         # 残差标准差构造区间
lower = np.maximum(fc - 1.96 * sigma, 0)     # 销售额非负 → 下界截断
upper = fc + 1.96 * sigma
mape = mean_absolute_percentage_error(test, fc_test)
```

### A.5　矩形树图 squarify 算法（Matplotlib 无原生支持，自行实现）

```
def squarify(sizes, x, y, w, h):
   # 始终沿当前矩形较短的一边排布，使子矩形长宽比尽量接近 1
   if len(sizes) == 1: return [(x, y, w, h)]
   half = int(len(sizes) / 2)
   if w >= h:  # 竖切
      ...
   else:       # 横切
      ...
```

## 附录 B　GitHub 仓库链接与目录结构

仓库地址（公开可见）：https://github.com/heee-a/business-data-analysis

GitHub Pages 大屏在线地址：https://heee-a.github.io/business-data-analysis/

```
business-data-analysis/
├── data/
│   ├── raw/        online_retail_II_raw_sample.csv(.gz)、provenance.json、sampled_invoice_ids.csv
│   ├── clean/      fact_order_items、dim_orders、dim_products、dim_customers、dim_date
│   │               retail_clean.sqlite(.gz)
│   └── schema/     data_dictionary.csv、star_schema.json、README_schema.md
├── scripts/
│   ├── 01_load.py      数据获取（官方下载 + 按发票抽样）
│   ├── 02_clean.py     清洗治理 + 星型模型 + 多格式导出
│   ├── 03_analysis.py  8 类商业分析模型
│   ├── 04_visuals.py   35 张静态图表（200dpi）
│   ├── 05_dashboard.py Pyecharts 交互大屏（20 组件）
│   ├── 06_report.py    期末大论文与图表索引生成
│   └── utils/          config.py / io_utils.py / style.py / chart_helpers.py
├── outputs/
│   ├── figures/    fig01 ~ fig35（35 张 PNG）
│   ├── tables/     69 个结果表（CSV + JSON）
│   ├── dashboard/  dashboard_dark.html（大屏）
│   └── html/       20 个独立组件 HTML
├── docs/           《商业数据分析》期末大论文.docx、图表索引.md、数据来源合规声明.md
├── pages/          index.html（GitHub Pages 入口）
├── requirements.txt    依赖清单
├── run_all.py          一键复现入口
└── README.md           项目简介、数据来源、复现步骤、图表索引、分工说明
```

## 附录 C　图表索引（fig01–fig35 + 大屏组件）

以下为正文未收录但在分析中同样关键的业务模型图，按模型顺序排列。

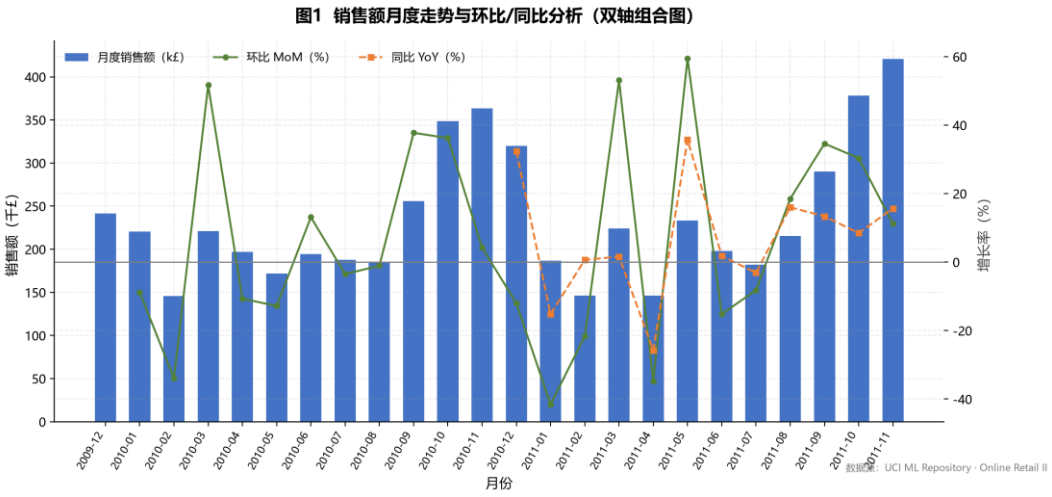



图 C-1　月度销售额环比/同比组合图（fig01_mom_yoy）




图 C-2 品类销售额矩形树图（fig23_treemap_category）

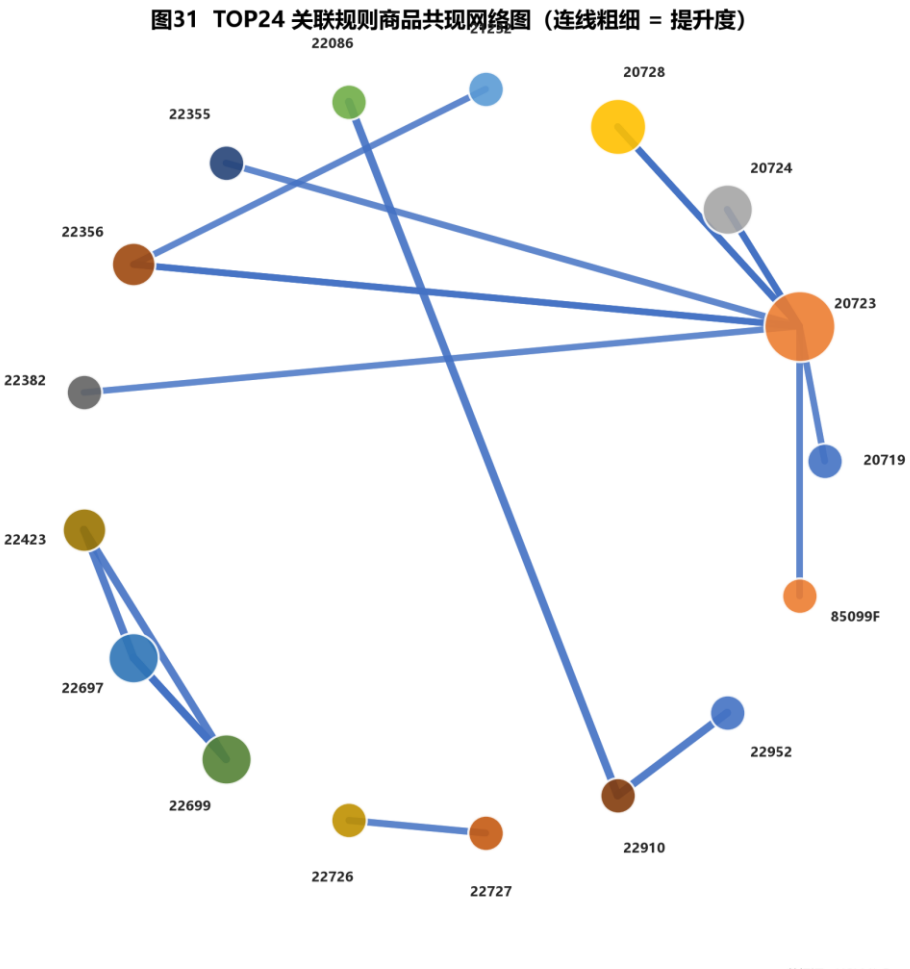


图 C-3 商品共现网络图（fig31_apriori_network）

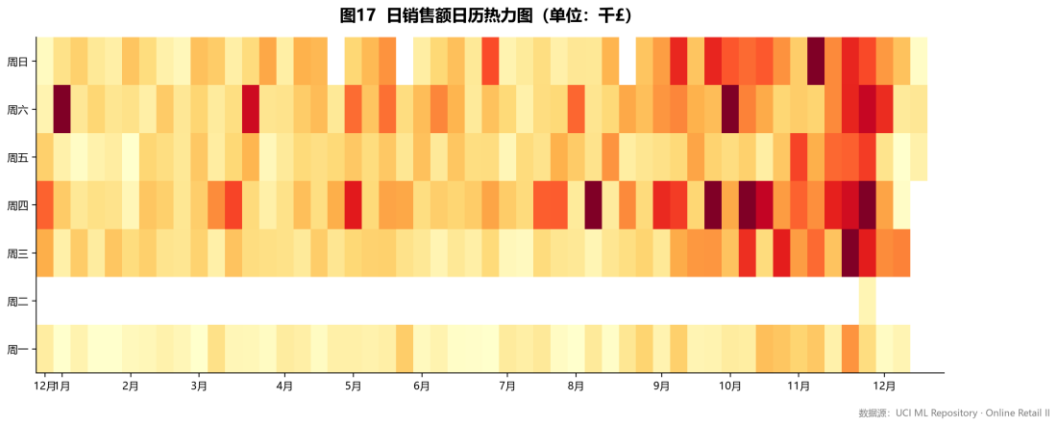



图 C-4 日销售额日历热力图（fig17_calendar_heatmap）

表 C-1 35 张静态图索引

| 编号 | 文件名 | 对应模板/模型 | 说明 |
|---|---|---|---|
| fig01 | fig01_mom_yoy.png | 组合图·环比同比 | 月度销售额柱 + MoM/YoY 双轴折线 |
| fig02 | fig02_revenue_trend_line.png | 折线图 | 日销售额趋势 + MA30 + 峰值标注 |
| fig03 | fig03_monthly_revenue_area.png | 面积图 | 月度销售额与订单量双面积图 |
| fig04 | fig04_top_countries_bar.png | 柱形图 | 国家销售额 TOP12 + 数据标签 |
| fig05 | fig05_top_products_barh.png | 条形图 | 商品销售额 TOP15 横向条形 |
| fig06 | fig06_country_donut.png | 环形图 | 国家销售额结构 + 中心总计 |
| fig07 | fig07_monthly_stacked_bar.png | 堆积柱形图 | 月度销售额国别构成 |
| fig08 | fig08_category_pct_stacked.png | 百分比堆积柱形图 | 月度品类结构占比 |
| fig09 | fig09_aov_frequency_scatter.png | 散点图 | 频次 × 金额 + 幂律趋势线 |
| fig10 | fig10_country_bubble.png | 气泡图 | 客户数 × 客单价 × 销售额 |
| fig11 | fig11_order_value_histogram.png | 直方图 | 订单金额分布 + KDE + 均值/中位数线 |
| fig12 | fig12_boxplot_country.png | 箱线图 | 主要国家订单金额分布 |
| fig13 | fig13_weekday_hour_heatmap.png | 热力图 | 星期 × 时段销售额 |
| fig14 | fig14_country_radar.png | 雷达图 | TOP5 国家五维指标对比 |
| fig15 | fig15_monthly_waterfall.png | 瀑布图 | 近 12 个月销售额增量链路 |
| fig16 | fig16_gauge_target.png | 仪表盘 | 年度目标达成率 + 年度对比 |
| fig17 | fig17_calendar_heatmap.png | 日历热力图 | 日销售额日历视图 |
| fig18 | fig18_slope_top_countries.png | 坡度图 | TOP8 国家年度规模变化 |
| fig19 | fig19_dual_axis_revenue_orders.png | 三轴组合图 | 销售额 + 订单数 + 客 |

| | | | |
|---|---|---|---|
| | | | 单价 |
| fig20 | fig20_rose_category.png | 玫瑰图 | 品类销售额南丁格尔玫瑰图 |
| fig21 | fig21_bullet_category.png | 子弹图 | 品类实际 vs 目标 |
| fig22 | fig22_violin_order_value.png | 小提琴图 | 各季度订单金额分布 |
| fig23 | fig23_treemap_category.png | 矩形树图 | 品类销售额面积占比 |
| fig24 | fig24_wordcloud_products.png | 词云图 | 热门商品描述词频 |
| fig25 | fig25_moving_average.png | 多重折线图 | MA7/MA30/MA90 趋势平滑 |
| fig26 | fig26_rfm_scatter_ch8.png | M2 RFM 模型 | RFM 八分类气泡矩阵 |
| fig27 | fig27_rfm_segment_bar.png | M2 RFM 模型 | 八分群客户规模 vs 金额贡献 |
| fig28 | fig28_cohort_retention_heatmap.png | M3 同期群留存 | 月度同期群留存热力图 |
| fig29 | fig29_pareto_abc.png | M4 帕累托/ABC | TOP30 商品帕累托 + ABC 分界 |
| fig30 | fig30_apriori_rules_scatter.png | M5 关联规则 | 支持度 × 置信度 × 提升度 |
| fig31 | fig31_apriori_network.png | M5 关联规则 | 商品共现网络图 |
| fig32 | fig32_bcg_matrix.png | M6 波士顿矩阵 | 相对份额 × 增速四象限 |
| fig33 | fig33_forecast_ci.png | M7 时间序列预测 | 点预测 + 95% 置信区间 + 回测 |
| fig34 | fig34_kmeans_clusters.png | M8 K-Means 分群 | 散点 + 分群画像对比 |
| fig35 | fig35_repurchase_funnel.png | M9 复购漏斗 | 五级复购转化漏斗 |

表 C-2 交互大屏 20 个组件清单

| 标签页 | 组件 | 标题 |
|---|---|---|
| tab1 | trend | 月度销售额趋势 |
| tab1 | dual | 销售额 × 订单数双轴 |
| tab1 | country_bar | TOP10 国家销售额 |
| tab1 | timeline | 月度国家排名时间轴 |
| tab1 | heatmap | 星期时段热力图 |
| tab2 | rfm_pie | RFM 金额贡献玫瑰图 |
| tab2 | rfm_bar | RFM 客群规模与贡献 |
| tab2 | cohort | 同期群留存曲线 |
| tab2 | funnel | 复购漏斗 |
| tab2 | kmeans | K-Means 分群画像 |
| tab3 | top_products | TOP10 热销商品 |
| tab3 | cat_pie | 品类结构环形图 |
| tab3 | wordcloud | 热销商品词云 |
| tab3 | abc | ABC 分类贡献 |
| tab3 | rules | 关联规则 Lift 排行 |
| tab3 | table | 商品明细表 |
| tab4 | forecast | 预测与置信区间 |
| tab4 | backtest | 回测对比 |
| tab4 | yoy | 同比增速复盘 |
| tab4 | bcg | 波士顿矩阵 |

完整索引（含栅格宽度与交互能力说明）见仓库 docs/图表索引.md；大屏演示文件见 outputs/dashboard/dashboard_dark.html。